

一、 摘要 (Abstract)

本研究以 huggingface 平台之 steam-games-dataset 為資料來源，透過資料前處理與特徵工程，建立與價格、評論、語言、平台、發行時間及內容設計相關之指標，並以 owners_log 作為遊戲熱門程度的 proxy 進行分析。透過探索性資料分析，結果顯示遊戲熱門程度呈現長尾分布，評論數與價格與 owners_log 具有較強關聯，語言數與成就數則僅呈現相對有限且分散的影響。在建模部分，本研究比較 Baseline、Decision Tree 與 Random Forest 迴歸模型，使用 MAE、RMSE 與 R^2 作為評估指標，結果顯示樹模型之預測表現明顯優於 Baseline，且 Random Forest 的 R^2 約達 0.83–0.84。特徵重要性分析進一步指出，review_log 與 price_log 為解釋與預測遊戲熱門程度的關鍵變數，與 EDA 觀察相互印證，顯示結合多維特徵的樹模型可有效協助理解現有 Steam 遊戲熱門程度的影響因素。

二、 前言 (Introduction)

(一) 研究動機

隨著電玩產業到快速發展，電玩已在全球娛樂產業佔有一席之地，幾乎人人接觸過，但我們發現電玩間的熱門程度存在極大的差距，有些遊戲在短時間內迅速累積大量玩家與好評，但也有許多遊戲在上市後幾乎沒有受到關注。而使一款遊戲受歡迎的因素往往十分複雜，可能與價格、遊戲類型、語言支援、玩家評價數量、遊玩時數、發售時間等特徵相關。

因此，我們希望透過資料分析的方法，探討究竟是哪些因素影響不同遊戲的熱門程度。藉由對 Steam 平台大量遊戲資料的整理與分析，我們希望能找出與玩家數量高度相關的特徵，並了解市場中熱門遊戲與非熱門遊戲之間的差異。

(二) 研究目的

1. 整理並分析 Steam 遊戲的各項特徵，包含價格、評價數量、好評率、語言支援、平台支援與遊戲類型等，了解其分布與基本特性。
2. 探討遊戲特徵與熱門程度 (estimated owners) 之間的關係，找出可能影響玩

- 家數量的重要因素。
3. 建立並比較多種機器學習模型（Baseline、Decision Tree、Random Forest），評估模型對現有遊戲熱門程度的預測能力，以驗證不同特徵之間的影響程度與可預測性。
 4. 分析模型的特徵重要性（Feature Importance），了解哪些特徵在預測遊戲受歡迎程度中扮演關鍵角色，並透過模型結果進一步驗證 EDA 中的觀察。

三、 方法 (Method)

(一) 資料來源與資料集描述

本研究使用之資料集為 hugging face 上提供之 steam-games-dataset

此資料集共有 83560 筆資料，欄位總數量為 38 筆，且最近更新時間為 2025 年 4 月 27 日。使用此資料集原因主要有三點：資料量大、特徵豐富、資料時間新。

其中，本研究主要使用以下類別之核心欄位

分類	欄位	原因／用途
基本資訊	Name, Release date, Required age, Price	基本屬性與時間分析用；可研究價格、分級與年份趨勢。
銷量／熱度	Estimated owners, Peak CCU, Recommendations	作為銷量或人氣 proxy；分析遊戲成功的市場因素。
相容性與覆蓋範圍	Supported languages, Windows, Mac, Linux	探討語言與平台覆蓋度對市場與評價的影響。
評分相關	Metacritic score, User score, Positive, Negative	建立品質指標與市場反應關係（專業 vs 玩家）。
玩家行為	Average playtime forever, Average playtime two weeks, Median	衡量長期與短期黏著度、遊戲內容深度與熱度變化。

	playtime forever, Median playtime two weeks	
內容延伸	DLC count, Achievements	評估內容持續性與成就設計對玩家黏著度的影響。
公司屬性	Developers, Publishers	分析大型公司與獨立開發商的市場差異。
遊戲分類	Genres, Categories	作為群組分析基礎；探索不同類型與玩法的市場表現。

本研究後續將針對上述欄位進行前處理、特徵工程與分析，以探討影響遊戲熱門程度的主要因素。

(二) 資料前處理

為了確保後續分析與建模的品質，本研究在使用原始 Steam 遊戲資料前，先進行欄位篩選、缺值處理、日期轉換、銷量區間轉換與重複資料清理等前處理步驟。透過這些處理，可以保留與研究主題最相關的欄位，同時減少缺失與異常值對結果的影響。

1. 欄位篩選與缺值處理

- (1) 根據分析目標僅保留 27 個核心欄位作為後續分析使用
- (2) 刪除無 Name 的資料共 6 筆
- (3) 針對文字類欄位: Developers, Publishers, Categories, Genres 缺失率約 4%~5%，考慮兩種處理方式:直接刪除及補植，由於直接刪除資料筆數會減少至約 78583 筆，故以 Unknown Developer、Unknown Publisher、Uncategorized、Unknown Genre 進行補植。

2. 日期轉換(Release date)

- (1) 將文字型日期轉換為 datetime 格式。
- (2) 新增 release_year (年份) 與 release_month (月份) 欄位，方便進行時間趨勢分析。

3. 銷量區間處理 (Estimated owners)

- (1) 原資料為字串區間 (例如 "0 - 20000")，將上下限取平均值後轉為中位數，建立新欄位 owners_mid 作為銷量 proxy。

4. 重複資料處理

- (1) 檢查資料集發現共 6 筆重複遊戲名稱（可能為重製版或重複記錄），已刪除以避免統計偏誤。

(三) 特徵工程

為後續研究便利，共新增 16 個新特徵欄位，具體如下：

這些特徵可應用於：觀察價格、好評率、語言數與平台對銷量的影響，找出玩家評價與銷量、活躍度之間的關聯及作為預測「好評率」或「銷量 proxy」的自變數。

1. 基礎衍生特徵

針對核心欄位進行運算與轉換，建立更具代表性的數值與比率型特徵。主要包含評價、語言、平台與遊玩行為等面向，協助量化遊戲特性。

特徵名稱	計算方式	說明
positive_rate	Positive / (Positive + Negative)	好評率，用於衡量玩家滿意度，避免僅以好評數判斷。
lang_count	len(Supported languages)	支援語言數，代表遊戲國際化程度與潛在市場規模。
audio_lang_count	len(Full audio languages)	支援語音語言數，常見於大型或敘事型作品。
audio_lang_ratio	audio_lang_count / lang_count	語音語言佔總語言比例，間接反映開發資源投入。
platform_count	Windows + Mac + Linux	支援平台總數，用於分析跨平台程度。
playtime_ratio_recent	Average playtime two weeks / (Average playtime forever + 1)	近期 vs 總遊玩時數比，衡量遊戲近期熱度與玩家留存度。

2. 延伸行為與熱度特徵

進一步結合評論、價格與遊玩時數建立指標，用於評估遊戲受歡迎程度與經濟表現。

特徵名稱	計算方式	說明
review_count	Positive + Negative	總評論數，代表遊戲討論度與玩家活躍度。

review_log	np.log1p(review_count)	對數化評論數，減少極端遊戲對分析的影響。
review_balance	(Positive - Negative) / (Positive + Negative)	評價極性，越接近 1 表示評價越正向。
price_log	np.log1p(Price)	對數化價格，減少極端高價遊戲對分析的影響。
owners_log	np.log1p(owners_mid)	銷量 proxy 取對數，使分布更平滑。
is_free	(Price == 0)	標記免費遊戲，用於區分不同營運策略。
playtime_hours	Average playtime forever / 60	轉換為小時單位，便於視覺化與比較。

3. 類別與評價特徵

將文字型欄位轉換為主要分類與對應統計，方便群組或關聯分析。

特徵名稱	計算方式	說明
main_genre	Genres.split(',')[0]	取第一個遊戲類型（如 Action、RPG）。
genre_count	len(Genres.split(','))	類型數量，用於衡量混合類型程度。
main_category	Categories.split(',')[0]	取主要遊戲類別（如 Single-player、VR）。
rating_gap	User score - Metacritic score	比較媒體與玩家評價落差。
release_decade	(release_year // 10) * 10	將年份劃分為年代，用於長期趨勢分析。
is_recent	(release_year >= 2020)	標記 2020 年以後發行的新遊戲。

在設計上述特徵前，本研究先透過探索性資料分析 (EDA) 觀察各變數的分布與 owners_log 的關係，作為對數轉換、比例特徵與類別欄位處理方式的參考，相關圖表與觀察將於後續實驗結果中說明。

(四) 模型與實驗設計

本研究將 owners_log 視為連續型目標變數，問題設定為監督式迴歸任務，輸入特徵為前述經過前處理與特徵工程後的欄位，用於預測遊戲熱門程度並分析其影響因素。為了提供基準，我們首先建立一個 Baseline 模型，對所有樣本一律以訓練集中 owners_log 的平均值進行預測，作為後續比較

其他模型表現的參考。

接著，本研究使用決策樹迴歸 (Decision Tree Regressor) 與隨機森林迴歸 (Random Forest Regressor) 作為主要方法。決策樹可以清楚的規則形式呈現決策路徑，方便解讀價格、評價與評論數等特徵對預測結果的影響，且其可以處理非線性之特徵，但易發生過度擬合。隨機森林則為多棵決策樹之集成模型，可透過 bootstrap 抽樣與特徵隨機選取降低過擬合風險。

實驗設計上，我們將處理完成的資料以 80:20 的比例隨機切分成測試集和訓練集，並固定 random_state=42 以確保可重現性，所有模型都使用相同的特徵與資料切分方式來訓練和評估。評估方面，我們採用平均絕對誤差 (MAE)、均方根誤差 (RMSE) 和決定係數 (R^2) 三個常見的迴歸指標，分別用來衡量預測誤差的平均大小、對大誤差的敏感程度，以及模型對目標變異的解釋能力。

四、 實驗 (Experiments)

(一) 資料集與環境

1. 資料集

本研究使用 Hugging Face 上提供之 steam-games-dataset，包含約 83,560 筆遊戲資料與 38 個欄位，最近更新時間為 2025 年 4 月 27 日。資料內容可參考 Method 內容

2. 作業環境

本研究主要在 Windows 作業系統下以 Visual Studio Code 搭配 Python 3.13.2 進程式撰寫與實驗。

3. 使用套件

資料讀取與清理主要使用 pandas 與 numpy，視覺化則採用 matplotlib 與 seaborn。機器學習相關實驗透過 sklearn 套件實作。

(二) 實驗設定

本研究的預測目標為 owners_log，將問題設定為監督式迴歸任務，並使用前

一章完成前處理與特徵工程後的特徵作為模型輸入。在模型部分，我們比較三種方法：以訓練集中 `owners_log` 平均值作為輸出的 Baseline 模型，以及決策樹迴歸 (DecisionTreeRegressor) 與隨機森林迴歸 (RandomForestRegressor)，用來評估樹模型相較於簡單基準的預測表現。

各模型使用之參數如下：

1. 決策樹迴歸：

- (1) `max_depth=10`
- (2) `random_state=42`
- (3) 其餘使用套件預設值

2. 決策樹迴歸：

- (1) `n_estimators=300`
- (2) `max_depth=20`
- (3) `min_samples_split=5`
- (4) `min_samples_leaf=2`
- (5) `random_state=42`
- (6) `n_jobs=-1`
- (7) 其餘使用套件預設值

模型輸入特徵包含價格與營運相關的 `price_log`、`is_free`，評價與討論度相關的 `review_log`、`positive_rate`、`review_balance`，語言與平台覆蓋度相關的 `lang_count`、`platform_count`，時間與世代相關的 `release_year`、`is_recent`，以及 `Achievements`、`DLC count` 等內容設計指標。

在資料切分部分，本研究將處理完成的資料隨機分成 80% 訓練集與 20% 測試集，並固定 `random_state=42`，以確保每次實驗使用相同的資料切分。所有模型皆在相同的特徵集合與訓練／測試切分下訓練與評估，使不同模型之間的比較具有一致性與公平性。

(三) 評估指標

本研究使用平均絕對誤差 (Mean Absolute Error, MAE)、均方根誤差 (Root Mean Squared Error, RMSE) 以及決定係數 (R-squared, R^2) 作為個模型結果之評估指標，分項說明如下：

1. MAE

MAE 衡量預測值與真實值之間的平均絕對誤差，其數值越小表示模型預測越準確。公式為「 $MAE = (1/n) * \sum |y_i - \hat{y}_i|$ 」。

2. RMSE

RMSE 為常用的迴歸評估指標，比 MAE 對大誤差更敏感，可用來觀測模型是否存在明顯偏差或離散預測。公式為「 $RMSE = \sqrt{(1/n) * \sum (y_i - \hat{y}_i)^2)}$ 」。

3. R^2

R^2 衡量模型能解釋資料變異量的程度，範圍為 $(-\infty, 1]$ ，數值越接近 1 代表模型表現越好。公式為「 $R^2 = 1 - (\sum (y_i - \hat{y}_i)^2) / (\sum (y_i - \bar{y})^2)$ 」。

由於本研究所使用之模型為現實資料，變因較大，故 $R^2 > 0.6$ 可視為表現不錯。

(四) 結果

1. 探索性資料分析結果 (EDA)

本節首先透過探索性資料分析，檢視 Steam 遊戲資料的整體分布，並觀察各項遊戲特徵與熱門程度指標 `owners_log` 之間的關係，作為後續模型建構與解讀的重要基礎。




圖 1 `owners_log` 分布圖

圖 1 顯示 `owners_log` 的分布，大多數遊戲集中在約 9 左右的區間，僅

有少數遊戲位於更高的 `owners_log` 值，整體仍呈現右偏分布，代表多數遊戲的玩家數有限，只有少數作品格外熱門。




圖 2 價格 (`price_log`) 和熱門程度 (`owners_log`) 散布圖




圖 3 價格 (`price_log`) 和熱門程度 (`owners_log`) 箱型圖

圖 2 顯示價格對數 (`price_log`) 與 `owners_log` 的散佈關係，圖 3 則比較不同價格區間的 `owners_log` 分布。

自圖 2 可得，多數遊戲集中於中低價位區間，且在各價位都存在少數玩家數極高的作品，整體趨勢不完全線性。

圖 3 進一步顯示，極低價(0-5 美元)遊戲的 `owners_log` 中位數反而低於中價位區間(10-50 美元) 顯示中價位作品平均而言能吸引較多玩家，價格過低並不必然帶來更高熱門度。




圖 4 評論數 (review_log) 和熱門程度 (owners_log) 散布圖

圖 4 顯示對數評論數 (review_log) 與 owners_log 的關係，整體呈現明顯的右上傾斜分布：當 review_log 增加時，點雲逐漸往較高的 owners_log 擴散。

這說明總評論數越多的遊戲，其預估玩家數通常也越高，review_log 可視為反映遊戲討論度與市場熱門程度的重要指標。




圖 5 發行年度 (release_year) 和熱門程度 (owners_log) 折線圖

圖 5 顯示不同發行年份遊戲的平均擁有者數量趨勢，陰影區域為信賴區間。整體來看，2000 年前後的遊戲平均 owners_log 較高，之後隨年份緩步下降，代表越新的遊戲在樣本中平均擁有者數較少，可能與老遊戲累積時間較長或資料較偏向熱門經典作品有關。近年（約 2020 年後）曲線明顯快速下滑，推測與資料中非常新、尚未累積玩家數的作品較多，以及樣本期間尚未

完全觀察到長期表現有關，因此在解讀年代效果時需要保留彈性。




圖 6 語言數 (lang_count) 和熱門程度 (owners_log) 散布圖




圖 7 語言數 (lang_count) 和熱門程度 (owners_log) 箱型圖

圖 6 為支援語言數與 owners_log 的散佈圖，可以看到點雲分布相當分散，回歸線僅呈現輕微的負斜率，顯示語言數量與熱門程度之間並未形成明顯的線性關係。

圖 7 進一步將語言數分為 1-5、6-10、11-20、21-50 與 50 以上等區間，比較各組 owners_log 的分布；其中 6-10 與 11-20 語言組別的中位數略高於僅支援 1-5 種語言的遊戲，但整體差異有限，表示多語言支援對熱門程度的影響相較於評論數與價格較為間接。




圖 8 成就數 (Achievements) 和熱門程度 (owners_log) 箱型圖

圖 8 顯示 Achievements 與 owners_log 的關係，整體而言，成就數較多的遊戲中出現了一些 owners_log 較高的案例，回歸線亦呈現正斜率，暗示成就設計可能與玩家數存在一定程度的正向關聯。

不過，大多數遊戲的成就數仍集中在較低區間，且點分布相當分散，相較於評論數與價格，Achievements 對熱門程度的解釋力較弱。




圖 9 主要遊戲類型直方圖

圖 9 顯示本研究資料集中主要遊戲類型的數量分布，其中 Action、Adventure 與 Casual 為前三大類型，合計佔據多數樣本，反映 Steam 平台以動作與休閒向遊戲為主的生態。




圖 10 主要特徵相關係數熱圖

圖 10 為主要數值特徵之間的皮爾森相關係數熱圖，其中 `owners_log` 與 `positive_rate` 的相關係數約為 0.58，與 `price_log` 約為 0.40，與 `review_balance` 約為 0.36，顯示好評率與價格水準、評價極性與熱門程度之間存在中度正相關。

相較之下，`lang_count`、`Achievements` 與 `DLC count` 與 `owners_log` 僅呈現弱相關，與前述散佈圖及箱型圖的觀察一致，顯示這些特徵對玩家數的影響較為間接。




圖 11 評價極性、對數價格與對數擁有者數 3D 散佈圖

圖 11 顯示在相似價格區間下，review_balance 越接近 1（評價越正向）的遊戲，其 owners_mid (log) 多分布於較高區域，表示評價較好的作品通常能吸引較多玩家；然而，圖中亦可見部分評價普通但擁有者數仍偏高的案例，暗示熱門程度仍同時受到價格與評論數等其他因素影響。




圖 12 對數評論數、對數價格與對數擁有者 3D 散佈圖

圖 12 顯示在相似價格區間下，review_balance 越接近 1（評價越正向）的遊戲，其 owners_mid (log) 多分布於較高區域，表示評價較好的作品通常能吸引較多玩家；然而，圖中亦可見部分評價普通但擁有者數仍偏高的案例，暗示熱門程度仍同時受到價格與評論數等其他因素影響。

2. 模型預測結果

Model	MAE	RMSE	R ²
Baseline	2.1947	3.4451	-0.0001
Decision Tree	0.6220	1.4091	0.8327
Random Forest	0.6150	1.3937	0.8363

表格 1 各模型預測結果

表 1 彙整 Baseline、決策樹與隨機森林三種模型在測試集上的預測表現。Baseline 僅以訓練集中 owners_log 的平均值作為預測，其 MAE 約為 2.19、RMSE 約為 3.45，R² 約為 -0.0001，幾乎無法解釋目標變異。

相較之下，決策樹模型的 MAE 降至約 0.62，RMSE 約 1.41，R² 提升至

0.83，顯示樹模型已能有效捕捉特徵與熱門程度之間的非線性關係。

隨機森林模型進一步將 MAE 降至約 0.62 以下、RMSE 降至約 1.39， R^2 提升至 0.84 左右，為本研究表現最佳的模型，說明集成多棵決策樹有助於提升預測穩定度與準確度。

整體而言，Decision Tree 與 Random Forest 的 R^2 皆約在 0.83 以上，MAE 約 0.62，顯示本研究所建構的模型在預測現有 Steam 遊戲熱門程度（owners_log）方面具有不錯的解釋力與預測表現。其中隨機森林的表現最佳，相較於 Baseline 顯著降低了預測誤差，代表引入價格、評論數與語言數等特徵，確實有助於提升對熱門程度的預測能力。

3. 特徵重要性分析




圖 13 Decision Tree 特徵重要性圖

圖 13 為以決策樹迴歸模型計算出的各個特徵重要性，其中可看到 review_log 與 price_log 兩個條狀明顯最長，代表評論數與價格對 owners_log 預測的貢獻度最高。其次像 release_year 與 lang_count 雖然也有影響，但權重明顯小很多，而包含各類型與是否免費在內的其他特徵幾乎貼近 0，表示在這棵樹的分裂過程中較少被用來做關鍵切分。




圖 14 Random Forest 特徵重要性圖

圖 14 顯示隨機森林迴歸模型估計的特徵重要性，橫軸為重要性數值，縱軸為各項輸入變數名稱。由圖可見，review_log 與 price_log 的重要性明顯高於其他特徵，分別反映評論數量與價格水準在預測 owners_log 時扮演主要角色；release_year 與 lang_count 也具有一定權重，代表發行時間與支援語言數仍對熱門程度有影響，而 Achievements 的貢獻略低，其餘平台數與各類型、是否免費等變數的重要性皆接近於零，對模型決策影響有限。

綜合兩模型之特徵重要性結果，可發現兩者重合度極高，且 review_count、price_log 之重要性明顯高於其於特徵，顯示討論度及價格對遊戲熱門程度有極大影響，其次為發行年份和語言數量。

五、 討論與分析 (Discussion/Analysis)

1. 由圖 1 可得，大多數遊戲 owners_log 集中在約 9 左右的區間，僅有少數遊戲位於更高的 owners_log 值，整體仍呈現右偏分布，代表多數遊戲的玩家數有限，只有少數作品格外熱門。這種型態與數位內容市場常見的長尾現象相符：少數高知名度或具強烈話題性的作品能聚集大量玩家，而多數遊戲則維持在相對小眾的規模。

2. 圖 2 和圖 3 顯示，price_log 與 owners_log 的關係並非單純線性，中價位遊戲的 owners_log 中位數反而高於極低價遊戲。而從模型特徵重要性中可得 price_log 也具有明顯權重，代表價格在區分熱門與非熱門遊戲時扮演重要角色。此現象可能為中價位之遊戲通常投入了一定的資源以及有一定的內容深度，比起極低價或免費遊戲更容易吸引玩家遊玩，故可以在維持合理價格的同時吸引較多玩家。
3. 由圖 4 可知，review_log 與 owners_log 呈現明顯的正向關係，評論數越多的遊戲通常擁有較高的預估玩家數。同時，模型特徵重要性亦顯示此為模型預測時最重要之特徵。此結果相當合理，評論數通常反映了玩家基數以及遊戲討論熱度。
4. 綜合 3D 視覺化結果可知，在多數價格區間下，review_count (log) 增加時，owners_log 整體有明顯上升趨勢，顯示評論數與熱門程度之間的正向關係在不同價位帶中皆相當穩定。同時，在相似價格下，評價越正向 (review_balance 越接近 1) 的遊戲，其 owners_log 普遍較高，表示價格、評論數與評價極性會共同影響玩家數，而非單一因素即可決定遊戲是否成為熱門作品。
5. 由圖 5 可知，較早發行的遊戲 (約 2000 年前後) 其平均 owners_log 較高，之後隨發行年份增加整體呈現下降趨勢，代表樣本中較新的遊戲平均擁有者數量反而較少。同時，模型特徵重要性亦顯示 release_year 在預測時具有一定權重，說明年代資訊確實會影響熱門程度的估計。此結果可能因較早發行的遊戲一方面有較長時間累積玩家，另一方面資料中也可能較容易收錄經典熱門作品；相對地，近期新作多仍在成長階段，尚未完全顯現長期表現，因此在解讀年代效果時需保留彈性，避免將其簡化為「新遊戲較不受歡迎」的因果關係。
6. 由圖 6 與圖 7 可知，語言數量與 owners_log 之間並未呈現明顯線性關係，僅能觀察到支援 6-20 種語言的遊戲中位數略高於僅支援 1-5 種語言的作品，整體差異仍相對有限。同時，在模型的特徵重要性中，lang_count 的重要性雖較前兩名稍低，但亦有一定重要向。此現象可能因多語言支援有助於擴大潛在市場與降低語言門檻，吸引更多玩家。
7. 由圖 8 可知成就較多的遊戲確實出現了 owners_log 較高的案例，回歸線亦呈現正斜率，暗示成就設計與玩家數之間存在一定程度的正向關聯。我們將成就多解讀為遊戲品質、遊戲深度可能較佳，類似遊戲可以屬於讓玩家可深度遊玩之遊戲，重點於提高玩家黏性，但相對較難吸引新玩

家，與圖中結果相符。

8. 圖 9 顯示，本研究資料集中以 Action、Adventure 與 Casual 為主要類型，合計佔據多數樣本，反映 Steam 平台整體偏向動作與休閒向遊戲的供給結構。這樣的分布相當合理，一方面主流類型通常擁有較大的潛在玩家族群與較成熟的開發生態，容易累積大量作品；另一方面，也可能代表資料集中對於較受關注或較常被發行的類型有一定程度的偏重。
9. 整體而言，本研究建立之決策樹與隨機森林模型預測表現皆十分良好，表示模型有高預測力、解釋力。此可能因為模型同時利用了評論數、價格與發行時間等與熱門程度高度相關的特徵，且樹模型能捕捉非線性關係與特徵交互作用，因此能更貼近遊戲實際的市場機制。

六、 結論 (Conclusion)

1. 本研究以 Steam 平台約 8 萬筆遊戲資料為基礎，透過前處理與特徵工程建立多項與價格、評論、語言、平台、發行時間與內容設計相關的指標，並以 owners_log 作為熱門程度 proxy 進行分析與預測。
2. EDA 結果顯示，遊戲熱門程度呈現明顯的長尾分布；評論數與價格與 owners_log 的關聯最為明顯。相較之下，語言數與成就數的影響則較為間接，資料分布也較分散。至於發行年份，較早推出的遊戲因累積時間較長，因此在玩家數量上自然會略高一些，形成一定的年代差異。
3. 在模型表現方面，Decision Tree 與 Random Forest 在各指標上皆明顯優於 Baseline，證實結合多種特徵的樹模型能有效預測現有遊戲熱門程度，其中 review_log 與 price_log 等特徵的重要性最高，與 EDA 的觀察相互呼應。
4. 綜合而言，此研究發現，玩家評論樹及價格為影響 Steam 遊戲熱門程度的核心因素，並且本研究使用模型可有效預測現有 Steam 遊戲之熱門程度。

七、 參考文獻 (References)

1. steam-games-dataset
https://huggingface.co/datasets/FronkonGames/steam-games-dataset?utm_source=chatgpt.com